

Reconocimiento de Lenguaje de Señas.

Universidad del Valle de Guatemala
Ciencia de Datos, sección 10
Castellanos, I; Pérez, M. y Rodríguez R.

Análisis exploratorio

El conjunto de datos utilizado fue ASL Alphabet, disponible en Kaggle. Este contiene fotografías de manos que representan las letras del alfabeto del Lenguaje de Señas Americano. El conjunto de entrenamiento original está formado por aproximadamente 87,000 imágenes distribuidas en 29 clases: las 26 letras del alfabeto y las clases especiales del, nothing y space.

Las imágenes originales están almacenadas en formato JPG y tienen una resolución de 200x200 píxeles. Cada una de las 29 clases contiene 3,000 imágenes.

Para conocer visualmente los datos se seleccionaron ejemplos de diferentes letras del alfabeto. Se comprobó que las fotografías muestran la mano centrada y con un fondo relativamente uniforme, aunque existen pequeñas diferencias en posición, escala, orientación e iluminación.

Figura 1: Ejemplos de cinco letras distintas del alfabeto ASL.



Debido al costo computacional de trabajar con las 87,000 imágenes originales, se seleccionaron aleatoriamente 700 imágenes de cada clase. La selección se realizó utilizando una semilla fija, lo que permite reproducir el mismo submuestreo. Al conservar la misma cantidad de imágenes para cada clase, el conjunto reducido continúa balanceado.

Separación de los datos

Las 700 imágenes seleccionadas de cada clase fueron divididas de manera estratificada en tres conjuntos independientes:

<i>Partición</i>	<i>Imágenes por clase</i>	<i>Total</i>
<i>Entrenamiento</i>	500	14,500
<i>Validación</i>	100	2,900
<i>Prueba propio</i>	100	2,900

Selección de Modelos

Red Neuronal Simple.

Se requiere un modelo con una red neuronal simple, el cuál procedería como sigue:

1. A las imágenes, que poseen cerca de 12,288 valores, se les aplica primeramente Flatten.
2. Se procederá a aplicarle una capa lineal, el cuál dará como salida 512 valores.
3. Se proseguirá a aplicar el ReLU.
4. Se sigue a aplicar Dropout.
5. Se llegará a aplicar nuevamente una capa lineal que reciba los 512 valores y devuelva 128 valores.
6. A este resultado se le procederá a aplicar nuevamente el ReLU.
7. Por último, se le aplicará una capa lineal que reciba los 128 valores y devuelva 29.

CNN simple

1. En este caso se aplica la primera convolución con tres canales de entrada con un volumen de salida de 16 características tras aplicar 16 filtros distintos.
2. Se aplica ReLU
3. Se aplica MaxPool
4. Se aplica una segunda convolución a las 16 características que devolverá 32 características.
5. Se aplica ReLU nuevamente
6. Aplicación de MaxPool
7. Tercera convolución sobre los 32 anteriores, con salida de 64 valores.
8. Aplicación de ReLU
9. Aplicación de MaxPool
10. Se aplica un Flatten
11. Aplicación de una capa lineal
12. Retorno de 29 clases

Segunda CNN

1. Se aplica una convolución que recibe los 3 canales y retorna 32 características
2. A este se le aplica un BatchNorm
3. Se procede a aplicar ReLU
4. Se aplica MaxPool
5. Segunda convolución que recibe los 32 valores de la primera y devuelve 64.
6. A este se le aplica un BatchNorm
7. Se procede a aplicar ReLU
8. Se aplica MaxPool
9. Tercera convolución que recibe los 64 valores de la segunda y devuelve 128.
10. Se aplicará un Global Average Pooling
11. Se aplica Flatten, que devuelve un vector con 128 valores
12. A este se le aplicará un Dropout
13. Se aplica una capa lineal
14. Retorno de 29 clases

Plan para procesamiento

Para la manipulación de las imágenes, se realizará un submuestreo de estas, y tras la separación en entrenamiento y prueba llevado a cabo en esta primera etapa se realizará una disminución de las dimensiones de 200×200 a 64×64 .

Tras este cambio se hará la aplicación de los modelos antes descrita con el conjunto de entrenamiento. Se procederá a la evaluación sobre el conjunto de prueba. Se evaluarán los modelos conforme a las siguientes métricas: Accuracy, Precision, Recall, F1, Matriz de Confusión y de ser necesario el tiempo de cómputo.

Modelos Evaluados

Se evaluaron cinco modelos para clasificar las 29 clases del dataset ASL.

Red neuronal fully-connected

El primer modelo fue una red neuronal simple que convierte cada imagen de 64x64 píxeles en un vector. Utiliza capas de 512 y 128 neuronas, activación ReLU y Dropout. Obtuvo un accuracy de 40.74 %, mostrando que la pérdida de la estructura espacial limita su capacidad para reconocer las señas.

CNN simple

La primera CNN utiliza tres capas convolucionales de 16, 32 y 64 filtros, acompañadas de ReLU y MaxPooling. Su accuracy fue de 10.93 %, siendo el resultado más bajo. La matriz de confusión mostró que solo consiguió reconocer adecuadamente algunas clases.

CNN con Batch Normalization y Dropout

La segunda CNN incrementa los filtros a 32, 64 y 128 e incorpora Batch Normalization, Global Average Pooling y Dropout. Alcanzó un accuracy de 37.33 %, superando a la CNN simple, aunque permaneció ligeramente por debajo de la red fully-connected.

CNN con aumento de datos

Se entrenó otra CNN aplicando rotaciones, zoom, traslaciones y flip horizontal a una parte de las imágenes. Este modelo obtuvo un accuracy de 61.34 %, lo que representa una mejora respecto de las redes anteriores. No obstante, el flip horizontal debe utilizarse con precaución porque puede alterar la orientación y significado de una seña.

Random Forest

Finalmente, se entrenó un Random Forest y se optimizaron sus hiperparámetros mediante GridSearchCV. La mejor configuración utilizó 300 árboles, profundidad máxima de 20 y max_features="sqrt". Obtuvo 85.41 % en validación cruzada y 88.32 % en prueba, por lo que fue el modelo con mejor desempeño.

Resultados

Los modelos presentaron diferencias importantes en su capacidad para clasificar las 29 clases ASL. Los resultados obtenidos se resumen en el siguiente cuadro.

Cuadro 5. Comparación del desempeño de los modelos.

<i>Modelo</i>	<i>Accuracy</i>
<i>Red neuronal fully-connected</i>	40.74 %
<i>CNN simple</i>	10.93 %
<i>CNN con Batch Normalization y Dropout</i>	37.33 %
<i>CNN con aumento de datos</i>	61.34 %
<i>Random Forest</i>	88.32 %

La CNN simple obtuvo el desempeño más bajo, con dificultades para reconocer la mayoría de las clases. La incorporación de Batch Normalization y Dropout mejoró el resultado, pero no superó a la red fully-connected. Por otra parte, el aumento de datos permitió que la CNN alcanzara 61.34 %, lo que indica una mejor capacidad de generalización ante variaciones en las imágenes.

Random Forest presentó el mejor desempeño, con 85.41 % de accuracy en validación cruzada y 88.32 % en prueba. Por esta razón, fue seleccionado como el mejor modelo. Su matriz de confusión mostró predicciones correctas para la mayoría de las clases, aunque presentó mayores dificultades con algunas letras visualmente similares.

Las métricas de las redes de Modelos.ipynb deben sustituirse si aún corresponden al entrenamiento anterior de una sola época. La comparación definitiva debe utilizar las salidas actualizadas después de ejecutar las cuatro épocas.

Referencias

Akash Nagaraj. (2018). ASL Alphabet [Dataset]. Kaggle.
<https://doi.org/10.34740/KAGGLE/DSV/29550>